

算力租赁调研

GPU / NPU 服务器 与大模型推理

硬件配置、模型适配与 Token 产出验证



2 台昇腾 910B + 4-6 台 NVIDIA T4

租赁方案与验证计划 2026.09.14

拟租算力与用途

先建立可重复的 Token 生成基线，再决定扩容数量


昇腾 910B

2 台 / 16 张 NPU

单机 $8 \times 64\text{GB} = 512\text{GB}$
两台标称总容量 1,024GB

优先验证 Qwen3.8-27B
大模型跨机方案另做验证

单台服务器加速卡总显存 (GB)



T4 : 4-6 台，32-48 张 GPU
全池 512-768GB，适合小模型多副本

容量为标称加总，不是单模型可直接使用的统一显存。来源：NVIDIA T4；910B 按本方案 64GB/卡假设

完整推理服务器的配置清单

加速卡之外，主机内存、磁盘和互联同样影响模型加载与运行



Atlas 800I A2 产品参考图


实际租赁机型待供应商确认
表内主机配置为询价起点

配置项	910B 服务器	T4 服务器
加速卡	8 × 64GB	8 × 16GB
CPU / 主机内存	厂家配套 CPU 建议 1-2TB RAM	32-64 物理核 建议 256-512GB
本地 NVMe	建议 4-8TB	建议 2-4TB
节点间网络	跨机优先 200GbE RDMA，核对完整链路	副本用 10/25GbE 跨机需单独测通信
交付环境	驱动 / CANN / 容器 设备权限与健康检查	驱动 / CUDA / 容器 PCIe / NUMA 拓扑

图片与整机规格参考：华为 Atlas 800I A2。CPU、RAM、NVMe 和管理网络为本方案建议，不是通用最低要求

两类硬件分池服务

请求路由统一接入，模型实例在同类硬件内运行



TP 将一个模型分到多卡。独立副本增加总吞吐，未必降低单请求延迟。

架构为本项目建议。T4 常见卡间通路为 PCIe，不能按 NVLink 互联假设规划

目标模型与权重规模

容量按全部驻留权重估算，MoE 激活参数量主要反映每步计算量

模型	参数口径	16 位权重粗估	关键适配点
Qwen3.8-27B	语言 27B 完整仓库约 28B	约 56GB	Gated DeltaNet 全注意力 / 视觉 / MTP
Qwen3.8-Flash-Next	主干 125B + n-gram 51B + MTP 4B，另含视觉	约 360GB 起	MoE / QSA / GDN 额外 embedding 驻留
GLM-5.3	完整仓库约 753B	约 1,506GB	量化格式与稀疏算子 跨节点专家通信
DeepSeek-V4.1-Flash	主干 552B 另加 Engram 等模块	主干约 1,104GB 全量更高	CED / CSA2 / Engram 原始权重 FP8 / FP4

本轮优先文本生成。视觉、超长上下文和推测解码分别验收。

来源：各模型 Hugging Face 官方模型卡与配置。权重粗估使用参数量 × 2 bytes，不包含缓存和运行开销

显存预算与精度约束

权重装得下只是第一道条件，运行峰值必须逐卡满足

单卡峰值显存



权重近似 = 参数量 × 每参数字节数 ÷ 分片数
再加入未分片模块、量化元数据和负载相关缓存

硬件	优先精度路径	关键限制
T4 / SM75	FP16；经验证的 AWQ / GPTQ 等 W4A16 权重与 kernel	无原生 BF16 / FP8 Marlin 支持 Turing，但不含 MXFP4
910B / Ascend	BF16 / FP16；ModelSlim W8A8 + Ascend 量化后端	CANN、驱动、vLLM-Ascend 配套 CUDA 专用 kernel 不能直接复用

示意块宽度不代表占比。来源：vLLM 量化兼容矩阵；Ascend 模型教程。KV 量化与权重量化需分别确认

910B：27B 优先，超大模型另设方案

范围：2 台 × 8 卡 × 64GB。以下为调研判断，尚未在租赁机器实测

模型	本轮结论	建议配置 / 主要证据
Qwen3-8B 基线	优先验证	单张 64GB，BF16，4K 上下文起测
Qwen3.8-27B	优先验证	单机 BF16 或 W8A8；官方 A2 量化示例 TP2
Qwen3.8-Flash-Next	容量可候选 算子待验证	单机 BF16 约 360GB 起；新增架构与驻留策略待适配
GLM-5.3	两台不作承诺	BF16 容量不足；W8A8C8 参考为 4 台 A2
DeepSeek-V4.1-Flash	两台不作承诺	W8A8 + INT8 Engram 参考为 4 台 A2 量化权重发布状态仍需确认

4 台 A2 / 2 台 A3 是文档参考配置，不能解释为理论最小卡数。

来源：vLLM-Ascend Qwen3.8-27B、GLM-5.3、DeepSeek-V4.1-Flash 教程；GLM-5.3 当前标为 Experimental

T4：小模型多副本更适合作为首批用途

单台 128GB 标称显存，扩到 4-6 台主要用于增加独立服务实例

模型	本轮结论	可尝试范围 / 主要限制
Qwen3-8B 基线	优先验证	2 卡 FP16，短上下文；跑通后评估单机多副本
Qwen3.8-27B	容量候选	8 卡 FP16 或 2-4 卡 W4A16 仅为容量方案 须验证 GDN、SM75、attention / 量化 kernel
Qwen3.8-Flash-Next	暂缓首批	原精度单机不足；低比特权重与 n-gram 策略待验证
GLM-5.3	不建议首批	需低比特与跨机并行，量化支持和通信成本未闭环
DeepSeek-V4.1-Flash	不建议首批	原始 FP8 / FP4 路径不适配 T4 原生能力 需要权重转换及新架构算子验证

T4 的数量不能替代对新模型 kernel 的验证。

来源：NVIDIA T4、vLLM 量化矩阵及官方模型卡。容量候选不代表已可运行，跨机总显存也不能保证可用

硬件能否运行模型的判断流程


每个判断都形成证据，最后用实际生成与负载测试验收



顺序按编号执行。方法为本项目验收设计；模型兼容证据见各框架官方支持矩阵与模型配方

Hugging Face 下载到首个 Token

先用 Qwen3-8B 检查环境，再切换目标模型的专用配方



Qwen3.8-27B 官方仓库页面

截图：Hugging Face / Qwen3.8-27B。下载方法：huggingface_hub CLI。完整示例与检查项见配套大纲

1 锁定版本

保存 repo、commit SHA 与模型配置

2 下载完整仓库

权重分片、索引、tokenizer、模板

3 选择软件栈

T4 用 CUDA ; 910B 用 CANN / Ascend

4 启动并生成

4K 上下文、并发 1；验证 API 输出

运行验收与 Token 产出测量

本方案不预填 tokens/s；性能结论以租赁交付环境的实测为准

测试负载



固定提示集与生成上限，按实际输出 Token 计数，记录 TTFT、TPOT 与完成吞吐。

现象	优先定位	验收证据
加载 / 推理 OOM	权重分片、KV、图捕获工作区	每卡峰值显存，失败请求与对应负载
算子报错 / NaN	模型架构、dtype、kernel 版本	日志、固定样本输出、精度回归
卡多却慢 / 通信超时	PCIe / NUMA、RDMA、并行方式	通信测试，TTFT / TPOT 的 p50、p95

建议持续测试至少 1 小时。输入长度 + 实际输出不得超过配置上下文。报告分别列明成功率及模型推理/正文 Token 口径

分阶段租赁与验收计划

先获得可复现的模型服务结果，再按真实业务负载确认租赁规模

阶段	执行范围	完成条件
第一阶段 设备与基线	各取 1 台验证，Qwen3-8B 首个 Token 核验 910B 64GB 与 T4 16GB 实卡	环境记录齐全 生成正确、设备与通信正常
第二阶段 目标模型验证	910B 优先 Qwen3.8-27B T4 评估小模型副本与 27B 适配	精度回归通过 固定负载下性能达到业务要求
第三阶段 租赁规模决策	据吞吐和报价确定 T4 为 4 台或 6 台 GLM / DeepSeek 大模型单独报价	每百万有效 Token 成本 持续运行与故障恢复通过

若 GLM-5.3 / DeepSeek-V4.1-Flash 是硬性目标

参考路径：补至 4 台 A2，或评估 2 台 A3。
先确认量化权重、专用镜像与网络，再做目标负载 PoC。

扩容是依据官方部署示例提出的候选方案，需供应商实测与报价确认。GLM 为实验支持，DeepSeek 量化产物需核验可获得性

附录 A：最小验证命令

起步命令示例，需先安装匹配镜像与驱动；完整请求和环境记录见配套大纲

下载：固定同一个 commit SHA

```
hf download Qwen/Qwen3-8B \  
--revision <已记录的 SHA> \  
--local-dir /data/models/Qwen3-8B
```

完整 snapshot 包含权重、索引与 tokenizer。

接口：POST /v1/chat/completions

检查返回文本、usage 与服务端错误日志。

910B 基线：使用匹配的 vLLM-Ascend 容器，dtype 改 bfloat16、TP 改 1。目标大模型按各自配方部署

T4：2 卡 FP16 的基线服务

```
vllm serve /data/models/Qwen3-8B \  
--dtype float16 \  
--tensor-parallel-size 2 \  
--max-model-len 4096 \  
--max-num-seqs 1 \  
--gpu-memory-utilization 0.85 \  
--enforce-eager \  
--served-model-name smoke-qwen3 \  
--host 127.0.0.1
```

附录 B：参考资料与交付清单

资料核验日期：2026 年 9 月 14 日；详细链接与计算依据见演讲者备注和配套大纲

官方资料

[硬件：Huawei Atlas 800I A2](#)

[硬件：NVIDIA T4](#)

[精度与 kernel：vLLM 量化矩阵](#)

[部署：Qwen3.8-27B / Ascend](#)

[部署：GLM-5.3 / Ascend](#)

[部署：DeepSeek-V4.1-Flash / Ascend](#)

[模型下载：Hugging Face CLI](#)

供应商交付时核验

- 01 板卡型号、显存及独占方式
- 02 CPU / RAM / NVMe 实际配置
- 03 卡间与跨机拓扑、RDMA 链路
- 04 驱动、CANN / CUDA、镜像版本
- 05 指定模型的输出与负载测试报告
- 06 租金、带宽存储费用及故障响应

本报告包含资料推导与待验证项，不包含租赁机器的实际 benchmark 结果