

GPU / NPU 租赁调研

硬件配置与 模型部署可行性

2 台 × 8 卡 910B / 4-6 台 × 8 卡 T4



01 硬件配置清单

02 模型适配结论

03 判断模型适配方法论

1.1 硬件范围与资源池

交付范围覆盖服务器、互联、存储、供电散热及管理接入



标称容量 : 910B 池 1,024GB ; T4 每台 128GB。跨卡、跨机容量需要软件显式分片。

架构为本项目方案 ; 硬件参考 : Huawei Atlas 800I A2、NVIDIA T4。异构资源池分别运行模型实例

1.2 单台服务器硬件清单

以下是完整租赁 BOM 的询价起点；主机配置为建议值，按最终模型修订

硬件项目	910B：每台，合计 2 台	T4：每台，合计 4–6 台
加速卡与承载	8 × 64GB；配套板卡互联	8 × 16GB；足量 PCIe 插槽 / 转接板
CPU / ECC 内存	厂家配套 CPU；1–2TB RAM	32–64 物理核；256–512GB RAM
系统盘	2 × 960GB SSD，RAID1	2 × 960GB SSD，RAID1
模型与缓存盘	本地 NVMe 可用容量 8TB 起	本地 NVMe 可用容量 4TB 起
网卡 / 管理口	配套 NPU RDMA；业务口；BMC	双口 25GbE；独立 BMC 管理口
机箱 / 电源 / 散热	完整机箱、导轨、冗余 PSU、风扇	支持 8 张被动散热卡的整机风道

容量均需以可用容量交付；系统盘 RAID1 不等于两块容量相加。参考：Huawei / NVIDIA；RAM、磁盘为项目建议

1.3 集群配套与最终交付环境

租赁合同应包含可运行的软件环境与对应硬件，不只交付可登录的裸机

配套硬件	数量 / 接口 / 交付要求
910B 互连网络	按整机 RDMA 端口配齐交换机、AOC 或光模块与光纤 若每台 8 × 200GE：共 16 条接入链路，交换容量同步核验
业务与管理网络	T4 双口 25G 共 8–12 个接入口；BMC 共 6–8 个接入口 补齐上联、网线、IP、路由；已有设备可复用
共享存储与机房	模型镜像与输出存储、备份目标；容量按留存量计算 机柜空间、导轨、双路供电 / PDU、散热与远程控制

910B 交付栈

Linux + 驱动 / 固件 + CANN
模型专用容器、HCCL / RDMA、设备权限

T4 交付栈

Linux + NVIDIA 驱动 + CUDA 容器
Transformers / TensorRT / Diffusers 按任务固定

每套环境记录镜像 digest、框架 commit、依赖锁文件和启动脚本；不同模型可使用不同容器

2.1 910B 模型适配结论

范围：2 台 × 8 卡 × 64GB；“配方支持”仍须在交付机器复验

模型 / 权重路径	本配置结论	关键依据
GLM-5.3 · W8A8C8 / W4	双机仍未确认	W8A8C8 参考 4 A2；双机 W4 完整链路未证实
GLM-5.3-Flash · W8A8	有双机 A2 配方	2 × 8 卡；DP2 / TP8 + EP，专用镜像与算子
DeepSeek-V4-Flash · W8A8	有单机 A2 配方	每台可独立部署；MTP / DSpark 要匹配版本
MiniMax-M3 · W8A8	有单机 A2 配方	至少 8 × 64GB；专用 MSA 与量化后端
DeepSeek-V4-Pro · W4A8	不满足当前配方	官方仍要求至少 4 A2，保留原结论
Qwen3.8-Flash-Next	拓扑仍待核验	有昇腾适配；缺双机 910B 同拓扑证明

依据：vLLM-Ascend 各模型专用教程与 FlagRelease；GLM-5.3 与 GLM-5.3-Flash 是不同架构 / 权重

2.2 910B 低精度部署条件

量化权重、推理框架、专用算子和设备拓扑必须采用同一套配方

模型	量化 / 框架与 kernel	双机使用方式与限制
GLM-5.3	W8A8C8；vLLM-Ascend 专用实现 不能把原始 FP8 当作 INT8 产物	约 753GB 只是 W8 权重粗估 参考 4 A2；W4 不能只算容量
GLM-5.3-Flash	W8A8；glm-5.3-flash 镜像 混合注意力 / mHC / MoE 专用算子	2 节点 DP2 / TP8 + EP 须配 HCCL；MTP 草稿使用 eager
DeepSeek-V4-Flash	W8A8-mtp；v0.23.0 配方 DSA / 混合 KV / MoE 昇腾算子	单台 8 卡可用，两台可分服务 0731 DSpark 用专用镜像 ≥0.25.0
MiniMax-M3	W8A8；文档基于 v0.27.1 MSA / MoE / Ascend 量化实现	单台至少 8 × 64GB 不能改用 950DT 的 MXFP8 配方

建议验证次序：DeepSeek-V4-Flash / MiniMax-M3 单机 → GLM-5.3-Flash 双机

来源：vLLM-Ascend 专用教程。不同模型分别固定镜像 digest；主机驱动 / CANN 兼容性逐一核对

2.3 T4 : 27B 文本推理与 YOLO

同一台 8 卡服务器按任务切分；模型层分配与多副本是不同方式

Qwen3.8-27B : 单机 8 卡 PoC

FP16 权重约 56GB，先用短输入、并发 1
Transformers + Accelerate 分配模型层
attention 用 eager，GDN 用 PyTorch 回退

仍需通过

FP16 无溢出；全部算子支持 SM75
逐卡峰值、生成质量及实际速度
“device_map”分层不是高效张量并行

YOLO26 : 官方 T4 路径可采用



在目标 T4 导出 engine，640 输入起测
按单卡实例扩展，检测不需要 8 卡 TP
INT8 另需代表性校准集和质量回归

官方同硬件测试 ≠ 本机交付已验收

来源：Qwen 官方模型卡、Transformers qwen3_5 源码；Ultralytics YOLO26 与 TensorRT 集成文档

2.4 T4 视频生成：Wan 与 HunyuanVideo

明确到版本和任务；低显存宣传值不能直接作为 T4 的部署证明

候选模型	容量与精度 / kernel 条件	T4 结论
Wan2.1-T2V-1.3B 480P 文生视频	官方低显存参考 8.19GB；不是 T4 实测 Diffusers 路径，CPU 卸载 / SDPA 回退 VAE 保留 FP32；DiT 的 FP16 数值需测	优先做 T4 视频 PoC 先短视频、单卡独立任务 不承诺官方 4090 的速度
Wan2.2-TI2V-5B 720P 文 / 图生视频	官方单卡卸载配方仍需至少 24GB 多卡 FSDP / Ulysses 有实现 但未证明 8 × T4 的完整执行链	单 T4 不满足该配方 多卡 / 量化列为专项验证 不能把 128GB 加总当证明
HunyuanVideo-1.5 8.3B 文 / 图生视频	官方卸载门槛 14GB；不是 T4 保证 原生脚本仅 BF16 / FP32，无 FP16 选项 FA / SSTA / FP8 路径需另核 SM75	列入候选，暂不承诺 评估 Diffusers 普通注意力 精度、峰值与画质均需实测

4–6 台 T4 优先扩展独立视频任务；单个视频使用多卡，需专门验证并行收益。


来源：Wan2.1 / Wan2.2、HunyuanVideo-1.5 官方仓库及 Diffusers 文档；均未在本项目 T4 实测

3.1 适配判断的完整逻辑

结论必须绑定：权重版本 × 软件栈 × 硬件拓扑 × 工作负载 × 质量要求



以上条件全部通过 (AND)



任一条件失败：当前方案不通过。缺少证据：标为待验证。修改精度或硬件后重新检查。

逻辑为本项目验收方法；“能下载”“能加载”“能生成”“满足生产负载”分别留证据

3.2 条件、证据与失败处理

每一项都必须回答“用什么证明通过”，不以模型名称相近代替兼容性

条件	通过证据	不通过时的动作
权重与架构	repo / SHA 完整；架构有实现	补齐文件；选择支持该架构的版本
精度与 kernel	逐模块 dtype / quant 格式匹配 目标 SM / NPU 实现或回退可运行	换后端或转换权重；重新验证数值
逐卡内存	权重 + 缓存 + 工作区峰值 每个 rank 均低于可用显存	缩减负载 / 改量化 / 增卡后重算
并行与通信	TP / EP / 分层合法；映射明确 设备拓扑、跨机通信测试通过	改分片；补齐互联；拒绝套用 A3 配方
主机与输出链	CPU / RAM / 磁盘满足加载与卸载 tokenizer / VAE / 解码等组件齐全	补资源或组件；生成完整目标输出
质量与服务	样本回归与目标负载测试达标	定位并重测；未达标不作为生产交付

证据固定到实际版本：模型 revision、容器 digest、框架 commit、驱动与 CANN / CUDA 版本

3.3 显存与精度的计算边界

模型适配使用逐卡运行峰值；总显存和平均分配只能做第一轮筛选

每个 rank 的峰值 = 权重 + KV / 状态 + 激活 / 工作区 + 通信 / 图缓存 + 余量


计算环节	具体做法
权重	读取实际张量 dtype 与量化配置；按实际分片归属求和 加入未量化模块、scale / zero-point、复制的 embedding
缓存与运行开销	按上下文、并发、图像尺寸或视频帧数估算，再实测峰值 GDN / MLA 等按实现计算，不直接套通用 KV 公式
精度匹配	“INT4 权重 + FP16 激活”与“FP4 + FP8”是不同路径 硬件、框架、打包格式、kernel 必须同时匹配

示例：DeepSeek-V4-Pro 理想全 4bit ≈ 800GB < 双机 1,024GB
但官方 W4A8 仍要求至少 4 A2，因此不能由这个不等式推出双机可部署。

参数量 × bit / 8 仅为权重粗估，采用十进制 GB。来源：DeepSeek 官方模型卡及 Ascend 专用部署教程

3.4 Hugging Face 到完整输出

每一步产生可保存的交付物；成功加载后仍需验证真实输出



官方模型页：模型身份与文件入口

截图：Qwen3.8-27B 官方 Hugging Face 仓库。下载与执行示例、证据模板见配套大纲

- 01 锁定与下载
保存 repo / SHA；完整 snapshot 与索引
- 02 静态审核
精度、kernel、内存、拓扑条件逐项过关
- 03 固定环境并启动
镜像 digest、依赖锁、设备映射与命令
- 04 真实样本生成
文本 / 检测框 / 可播放视频；检查有限值
- 05 回归与负载验收
质量基线、逐卡峰值、延迟及稳定性

3.5 三个实例的推导结果

同一套逻辑可以得到通过、待验证或不通过，而非统一给出“能跑”

判断条件	YOLO26s / T4	Qwen3.8-27B / 8 T4	V4-Pro W4A8 / 2 A2
权重 / 框架	官方权重与 TensorRT 路径	官方权重与 Transformers 实现	有 Ascend 专用量化路径
精度 / kernel	官方 T4 TensorRT10 测试	FP16 / eager / GDN 回退 完整数值与 SM75 待测	W4A8 不等于原生 FP4 按官方 Ascend 算子配套
容量 / 拓扑	单卡官方路径有依据 目标输入 / batch 复验	约 56GB 权重有容量空间 逐卡分层与峰值待实测	未满足参考至少 4 A2 理想 800GB 不是运行峰值
推导结论	官方同硬件可部署路径 交付机器仍需验收	允许 PoC 不能标“已确认可部署”	当前配方不通过 增至参考硬件或另找证明

完整证明 = 固定配置的证据清单 + 可复现启动 + 正确输出 + 目标负载达标。

来源：Ultralytics YOLO26；Transformers qwen3_5；vLLM-Ascend DeepSeek-V4-Pro。未进行本项目实机测试

3.6 最终验收与资料依据

交付结论应写成“某版本模型，在某配置和负载下通过”，保留复现实验

任务	必须交付的结果	性能 / 质量指标
文本生成	真实请求与完整回答；输入 / 输出 Token 计数	TTFT、TPOT、吞吐、错误率、质量回归
目标检测	检测框 / 类别 / 置信度；固定评估集结果	端到端延迟、FPS、mAP / 召回率
视频生成	可播放文件；帧数 / 尺寸 / FPS 与随机种子	秒 / 视频、峰值显存、黑帧与画质检查

共同证据包

硬件与拓扑清单 · 权重 SHA · 环境版本 · 启动脚本 · 原始日志 · 每卡峰值
固定负载测试与重启恢复；持续测试建议至少 1 小时，阈值由业务确认

[昇腾低精度配方](#)

[MiniMax-M3](#)

[YOLO / T4](#)

[Wan / 视频](#)

[模型下载](#)

公开资料核验日期：2026-09-14。所有来源按页置于演讲者备注；本报告不包含租赁机实际 benchmark