

token 魔方 Mini实验台

Token 生产与平台销售闭环验证

prepare:张帅

2026年9月16日

验证范围与评审目标

首轮用一个文本服务贯通生产、计量与平台对账，再验证真实结算回款。

A 技术验证

硬件设备与功率边界
网络拓扑与跨柜 RoCE
软件架构与 MASS 接入
模型适配与部署验收

B 商业验证

性能测算与可售产能
Token 收益与盈亏边界
商业协议与结算证据
公司流程与回款验收

本次评审形成：首轮服务范围、必补资源资料、平台试供给通过条件。

两台 910B 分柜，形成两个独立算力资源池

已确认 14 台服务器：16 张 910B NPU、48 张 T4 GPU及 6 台通算服务器。

机柜 A / 10 kW		机柜 B / 10 kW		设备	数量与核心配置
910B 服务器 ×1 8 张 NPU		910B 服务器 ×1 8 张 NPU		昇腾 910B	2 台 × 8 张 NPU 子型号与显存待盘点
T4 ×1 / 8 张 GPU		T4 ×1 / 8 张 GPU		NVIDIA T4	6 台 × 8 张 GPU 单卡 16GB GDDR6
T4 ×1 / 8 张 GPU		T4 ×1 / 8 张 GPU		通算服务器	6 台，已有机柜 CPU / 内存 / 系统盘 / 数据盘
T4 ×1 / 8 张 GPU		T4 ×1 / 8 张 GPU		RoCE 与光链路	1 台交换机，16 条链路 32 个 200GE 光模块

每柜 1 台 910B + 3 台八卡 T4 为拟议装载，须通过整机功率和安装核验。

混装能否上线，取决于逐柜整机峰值预算

10 kW 是机柜容量等级。八卡 T4 的 CPU、风扇和电源损耗都要纳入。


$$P_{910B} + 3 \times P_{T4} + P_{网络} + P_{预留} \leq P_{机柜可用}$$

配套类别	上线前必备项	核验重点
整机与存储	机箱、主板、CPU、内存、风扇、冗余电源 系统盘、模型/日志盘、按需磁盘控制器	八卡槽位、PCIe / Riser 峰值功耗与散热
网络与光纤	业务网卡、BMC 口、业务/管理交换机 RoCE 交换机、32 个光模块、16 组光纤	端口、上联线缆、管理网线 速率、接口和距离
机柜与机房	导轨、PDU、电源线、接地、理线 供电回路、UPS、制冷	持续容量、U 位、承重 冗余供电工况
既有 / 可选	6 台通算配套按现状盘点 可选共享存储、备份及存储网	复用边界、留存需求 不重复新增机柜

上架门槛：设备/运维提供两柜功率表和配件差缺清单，超限则调整 T4 分布。

跨柜可共用一台 RoCE 交换机

业务、带外管理与高速计算分网。柜体边界不增加交换跳数。



生态差异决定模型的部署路径


完整版本组合需要匹配驱动、运行时、模型算子和推理引擎。

层次	NVIDIA T4 路径	昇腾 910B 路径
硬件与设备	驱动、容器设备支持 T4 / SM75	驱动、固件、容器设备映射 910B 子型号待核
运行时与通信	CUDA、计算库、NCCL	CANN、算子库、HCCL
框架与模型	PyTorch、Transformers 量化权重及兼容 kernel	PyTorch + torch_npu 等适配 量化与算子工具链
任务与引擎	文本：兼容 vLLM YOLO：ONNX / TensorRT Wan：官方推理流程	国产文本：vLLM Ascend 或 MindIE 对应路径 按模型单独验证

先冻结可运行镜像再扩功能。T4 的 TensorRT 路径不能推导为 TensorRT-LLM 支持。

MASS 接入要保留从请求到用量的证据

6 台既有通算承载逻辑组件，具体能力归属和逐台部署待平台文档确认。



同一请求 ID 关联版本、状态、用量与账单。事件去重和重试计费分别处理。

910B 先完成一个稠密模型，再扩国产候选

筛选顺序：许可与平台规格、引擎支持、逐卡容量、通信、质量与负载验证。

候选模型	精度与起测路径	本轮判断与证据边界
Qwen / Qwen3-8B	BF16 或 FP16 短上下文、低并发起测	建议首个文本联调候选 官方 A2/A3 家族支持
DeepSeek-R1- Distill-Qwen-32B	16 位或适配量化 先核算权重 + KV + 工作区	进入条件性 PoC 蒸馏家族为实验性适配
zai-org / GLM-4.5-Air	16 位或匹配 W8A8 路径 核对 MoE 分片和通信	容量核验后再启动 家族支持不等于本台成功

逐卡峰值 = 本卡权重 + KV Cache + 激活/工作区 + 通信缓冲 + 余量

16 张卡是资源总量。910B 显存未知，暂不承诺完整 DeepSeek 大模型的双机容量。

T4 按三类任务部署，分别验证交付能力

6 台八卡服务器共 48 张 GPU。单卡 16GB，多副本和多卡并行按任务选择。

任务 / 首选候选	起测路径	验收指标与判断
量化文本 Qwen2.5-7B-Instruct-AWQ	vLLM + 兼容 AWQ kernel FP16 激活，先单卡短上下文	质量、TTFT / TPOT、Token/s 优先 PoC，实机待验
目标检测 YOLO26n	PyTorch 基线 ONNX / TensorRT 优化	mAP、召回率、端到端延迟 图片/帧吞吐，复验 T4 参考
视频生成 Wan2.1-T2V-1.3B	官方流程与必要卸载 核验 dtype / attention 后端	质量、分辨率/帧数/步数 生成耗时、视频/小时 条件性 PoC

文本模型按总参数 <20B 筛选。Wan 低显存参考不能证明 T4 的生成速度可交付。

模型发布以阶段证据为门槛

部署流程从设备验收开始，到可回退的服务版本结束。以下为待执行流程。

01 设备与网络

资产与健康记录
功率 / 光链路 / HCCL

02 环境与模型

镜像与权重校验
许可 / Tokenizer / 模板

03 服务启动

精度 / 上下文 / 并行
健康检查与启动日志

04 正确性

中文 / 多轮 / 流式
质量集与异常请求

05 MASS 与平台

鉴权 / 路由 / 计量
同批请求联调记录

06 性能与发布

稳定性 / 限流 / 恢复
配额、告警与回退版本

每阶段不通过即定位修复并回归。可发布产物是版本包、验收记录与回退配置。

压测同时扫描并发与请求到达率

先固定模型、任务规格和服务目标，再从单实例扩到资源池和平台入口。

并发初探

1 / 2 / 4 / 8 / 16 / 32

四类输入输出组合，分别测试未命中与重复前缀。边界未出现时继续加压。

```
vllm bench serve --backend openai  
--model <服务模型> --base-url <地址>  
--max-concurrency 8 --request-rate inf  
--save-result --save-detailed
```

执行与记录

预热后至少重复 3 次
记录样本数和测试窗口
保留实际到达率与错误率
检查客户端和接入层瓶颈

完整可复制脚本在备注及随附文件。示例参数是初探设定，正式阈值由平台需求确定。

可售产能来自满足质量与延迟条件的负载

结果判读方法：在同一请求集合、同一统计窗口内汇总，当前没有实测结果。

指标	计算或判读	对经营测算的影响
TTFT / TPOT	TTFT：发出请求到首 Token TPOT：(未到达时刻-首到达时刻) ÷ (输出 Token 数-1)	TTFT 含排队与网络 纯 Prefill 耗时需服务端 trace
并发与吞吐	报告实际并发、到达率、成功率 输入/输出 Token 数 ÷ 窗口秒数	选择满足服务目标的稳定负载 避免只取无约束峰值
计费 Token/s	同一窗口分别汇总合格输出 未命中输入、命中输入	request_goodput 单位是请求/s 缓存块数需映射为计费 Token
YOLO / Wan	检测质量 + 图片/帧吞吐 视频质量 + 任务数/小时	按任务规格单独计价 不套文本 Token 指标

产能交付表应绑定模型版本、卡数、任务规格、SLO、样本数和原始用量证据。

三类 Token 分别估值，采购价决定可结算收入

以下为产能计算口径。S = 30×24×3600 = 2,592,000 秒。

Decode 月价值 = $TGS_{out} \times S \times N_{out} \times P_{out} \div 10^6 \times \eta_{out}$
未命中 Prefill 月价值 = $TGS_{unc} \times S \times N_{unc} \times P_{unc} \div 10^6 \times \eta_{unc}$
命中 Prefill 月价值 = $TGS_{cache} \times S \times N_{cache} \times P_{cache} \div 10^6 \times \eta_{cache}$

公开市场参照 (USD / 百万 Token)	输出	输入未命中	输入命中
DeepSeek-V4.1-Flash 高峰	1.20	0.30	0.006
DeepSeek-V4.1-Flash 非高峰	0.60	0.15	0.003

价格查询：2026-09-16，仅作市场参照。该 API 与本台候选并非同一模型，不能代入报价。

TGS 按单卡才乘卡数；混合部署三类速率共用同一负载，已含损耗时不再乘同一 η 。

是否值得供给，要同时看增量收支和全成本

缺少实测产能、采购价与成本，当前能够给出盈亏条件，不能给出确定利润。

月经营结果 = 文本收入 + 检测收入 + 视频收入 - 项目成本

决策视角	纳入成本	能回答的问题
增量运营收支	新增电费、网络、机房与运维 按实际承担范围计入	已有设备试供给 能否覆盖新增现金支出
全成本经营结果	增量成本 + 折旧/租赁 既有通算和机柜的约定分摊	持续经营与后续扩容 是否具备经济性

盈亏边界：固定业务组合时，采购价系数 $k^* = \text{月成本} \div \text{基准月收入}$

采购价、需求利用、缓存比例和卡时分配分别做敏感性分析，资源重分配后需重测产能。

计量约定决定一条请求能否成为账单

拟议条款从平台接受的服务目录开始，连接双方认可的用量证据。



必须约定	拟议处理方式	留存证据
输入、输出与缓存	统一 Tokenizer 和缓存定义 三类单价、币种税费分别写明	规则版本、原始计数 平台与供应方明细
超时、重试、部分输出	逐类约定是否计费 重复事件去重，重试保留关联	attempt ID、状态 实际交付量与异常记录
对账差异与结算	确定权威依据、核验时限 冲正、补结算和账期	差异单、确认单 结算单与调整记录

技术可运行仍需平台认可模型、区域、容量与质量规格，才具备采购前提。

服务承诺应受当前架构和实测能力约束

拟议协议在可验收范围内确定服务窗口、维护、故障处理与责任。

当前约束	需要约定的边界	验收与责任证据
一台 RoCE 交换机	无交换机级冗余 维护窗口、故障响应与赔付边界	故障演练与恢复记录 运维联系人和升级路径
性能尚未实测	绑定模型、精度、上下文与配额 以验收负载确定服务目标	双方验收报告 监控口径与限流记录
模型与版本会变化	变更审批、回归测试和回退 禁用不满足许可的供给方式	模型权利依据 版本清单与发布记录
数据、暂停与退出	用途、留存、权限和责任分工 余额清算、数据处理与开票回款	访问与删除记录 最终对账单及回款凭证

SLA 数值和赔付条款留待验收及双方协商，现阶段不承诺未经验证的可用性。

公司交接以凭证推进，直至开票与回款

建议流程：技术、商务和财务在每个阶段明确接收什么产物。

责任角色	立项与准备	验收与试供给	月度经营与回款
项目负责人	资源与预算确认 首轮范围批准	阶段评审 试供给决策	经营复盘 后续资源决策
技术 / 运维	设备、网络和模型 版本与部署记录	质量/压测验收 接入、发布与回退	用量明细与告警 差异核验与复测
商务 / 法务	平台采购规格 模型与服务权利	报价和合同评审 双方验收确认	对账确认与争议 逾期跟进与变更
财务	成本边界与预算 价格口径核对	报价及结算条款 账期和开票要求	结算、开票与收款 凭证归档和分摊

同批请求贯通用量、对账确认、结算、发票与回款，才能宣称完成商业闭环。

下一阶段以一个可复现服务完成验证

当前已确认资源基线与分柜原则，模型、平台采购和实测证据仍需逐步补齐。

评审事项	进入下一阶段的通过条件	下一项证据 / 责任
首轮服务范围	Qwen3-8B 等具体版本完成质量、负载与计量联调	显存/功率清单、版本包设备运维与模型负责人
平台试供给	平台接受服务规格性能目标、采购价和规则明确	接入验收、报价与协议平台技术、商务、财务
商业闭环与扩容	同批真实用量完成结算回款订单需求和经济性支持扩容	对账单、回款、经营复盘商务、财务、项目负责人

当前决策建议：继续最小文本闭环验证。YOLO 与 Wan 保持独立 PoC。